

FOCUS TECHNIQUE — EXPLIQUÉ AVEC DES EXEMPLES CONCRETS INTELLIGENCE PRÉDICTIVE

Le moteur de scoring & l'IA prédictive

Comment le score est défini au démarrage, comment les critères sont choisis, comment sont déterminés le Next Best Action, le canal et le moment — et, une fois les campagnes lancées, ce que l'IA fait en continu et où l'humain garde la main. Illustré par un client fil rouge, #A-2481.

Cold-start & critères

XGBoost / LightGBM

NBA & éligibilité

Canal · K-Means

SHAP


IA / humain

une solution **Stratawise Africa**

01 • VUE D'ENSEMBLE

Le pipeline, de la donnée à la décision

Un enchaînement maîtrisé et reproductible : les données brutes sont préparées, un modèle par produit calcule une probabilité, le score est confronté à l'éligibilité, puis l'orchestration exécute. Les résultats reviennent réentraîner les modèles.



1 • Données

Référentiel client alimenté par le Core Banking, les transactions, la détention produit et les événements (simulations, réclamations).



2 • Préprocesseur

Un Pipeline scikit-learn nettoie et met en forme les variables — de façon identique à l'entraînement et à l'inférence.



3 • Modèles par produit

Un classifieur à gradient boosting par produit ; sortie = probabilité 0-1 convertie en score 0-100.



4 • Score → décision

Filtre d'éligibilité et de conformité, puis Next Best Action, canal et moment recommandés.

02 · DONNÉES & PRÉPROCESSEUR

Des variables brutes à une matrice exploitable

La qualité d'un modèle tient d'abord à la préparation des données. Un même Pipeline scikit-learn est ajusté sur les données d'entraînement puis appliqué à l'identique en production — ce qui évite toute fuite de données.

FAMILLES DE VARIABLES

Socio-démographiques

âge ancienneté segment région

Transactionnelles (RFM)

récence fréquence montant moyen flux

Détention & soldes

produits détenus encours épargne

Comportement canal

taux d'ouverture clics canal préféré heure d'activité

Événements

simulations réclamations événements de vie

LE PIPELINE (EXTRAIT) — SCIKIT-LEARN

```
# Pipeline scikit-learn – ajusté sur le train, appliqué à l'identique en inférence
num = Pipeline([("imp", SimpleImputer(strategy="median")),
                ("scale", StandardScaler())])
cat = Pipeline([("imp", SimpleImputer(strategy="most_frequent")),
                ("oh", OneHotEncoder(handle_unknown="ignore"))])

pre = ColumnTransformer([("num", num, num_cols),
                          ("cat", cat, cat_cols)])

model = Pipeline([("pre", pre),
                  ("clf", XGBClassifier(...))] # 1 modèle par produit
```

LES QUATRE ÉTAPES

1 Imputation

médiane / modalité
fréquente
SimpleImputer

2 Normalisation

mise à l'échelle homogène
StandardScaler

3 Encodage

catégories → binaires
OneHotEncoder

4 Matrice de features

vecteur prêt pour le modèle

03 · LE SCORING AU DÉMARRAGE (COLD-START)

Comment le score est défini le premier jour

Avant tout historique d'apprentissage, CampaignHub score déjà — à partir de critères métier pondérés. Ces critères sont définis conjointement, appliqués comme une **scorecard additive**, puis affinés par le ML.

QUI DÉFINIT LES CRITÈRES, ET COMMENT



Métier / Marketing

Fixe les signaux d'appétence (intérêt, détention, événements) et leur pondération, selon les objectifs commerciaux.



Data / IA

Recense les variables réellement disponibles et fiables, propose des proxies de conversion issus de l'historique.



Conformité

Fixe les règles d'éligibilité — consentement, exclusions, plafonds — qui priment toujours sur le score.

EXEMPLE — LA SCORECARD « JOUR 1 » DU CLIENT #A-2481

Critère (pondération définie avec le métier)	Constat — client #A-2481	Points
Ancienneté de la relation ≥ 3 ans	4 ans	+12
Revenus réguliers domiciliés	oui	+20
Simulations crédit récentes (90 j)	3	+25
Aucun crédit conso en cours	vrai	+10
Épargne disponible faible	vrai	+8
Incident de paiement récent	non	+2
Score d'appétence « Crédit conso » — jour 1		77

Résultat : score 77, client éligible (consentement OK, aucune exclusion) → il entre d'emblée dans le ciblage et le calcul du NBA.

04 · DU SCORE PAR RÈGLES AU SCORE PAR APPRENTISSAGE

Les règles démarrent, le machine learning prend le relais

La scorecard rend la solution opérationnelle immédiatement. Dès que les campagnes produisent des retours, le ML apprend les vraies pondérations et corrige ce que les règles ne voyaient pas.

SANS HISTORIQUE

Jour 1 — score par règles

- › Scorecard additive : des points par critère, calibrés avec le métier.
- › Transparent et immédiat, aucune donnée d'apprentissage requise.
- › Sert de garde-fou et de point de comparaison ensuite.

PILOTÉ PAR LES DONNÉES

Après N campagnes — score par ML

- › Le modèle apprend les vraies pondérations à partir des conversions.
- › Capte les interactions (ex. simulations × revenus domiciliés).
- › Score calibré = probabilité réelle, réévalué en continu.

CE QUE LE ML APPORTE CONCRÈTEMENT

Pondérations objectives

Issues des conversions réelles, plus des a priori — les critères qui comptent vraiment ressortent.

Interactions captées

Ex. « 3 simulations × revenus domiciliés » est plus prédictif que la somme des deux critères pris séparément.

Score calibré

La note reflète une probabilité réelle de souscription, comparable d'un produit à l'autre.

Client #A-2481 : score règles 77 → score ML 82


Le modèle valorise l'interaction simulations × revenus, invisible pour une simple somme de points.

05 · LE MODÈLE — UN CLASSIFIEUR PAR PRODUIT

Gradient boosting : XGBoost / LightGBM

Pour chaque produit, un modèle apprend à séparer les souscripteurs des non-souscripteurs. Le gradient boosting construit une succession d'arbres de décision, chacun corrigeant les erreurs du précédent — puissant sur des données tabulaires hétérogènes.

L'INTUITION



UN MODÈLE DISTINCT PAR PRODUIT

 Crédit conso AUC 0.81	 Carte premium AUC 0.78	 Épargne AUC 0.76	 Assurance auto AUC 0.74
Probabilité → score La sortie 0–1 du modèle est convertie en note d'appétence de 0 à 100, lisible par le métier.	Déséquilibre géré Les souscripteurs étant rares, la classe positive est pondérée (scale_pos_weight) pour ne pas être noyée.	Robuste au manquant LightGBM gère nativement les valeurs manquantes — moins de perte d'information.	

06 · JUSTIFICATION DU CHOIX

Pourquoi le gradient boosting plutôt qu'une autre approche

Sur des données bancaires tabulaires, mixtes et souvent incomplètes, XGBoost / LightGBM offrent le meilleur compromis entre performance, robustesse, rapidité et — point clé en environnement réglementé — explicabilité.

Critère (données bancaires tabulaires)	Régression logistique	Réseaux de neurones	XGBoost / LightGBM (retenu)
Interactions non-linéaires	●○○	●●●	●●●
Données hétérogènes mixtes	●●○	●●○	●●●
Valeurs manquantes	à imputer	à imputer	gérées nativement
Volume de données requis	faible	élevé	modéré
Explicabilité	●●●	●○○	●●● via SHAP
Vitesse entraînement / inférence	●●●	●○○	●●●

Échelle indicative : ●●● adapté · ●●○ moyen · ●○○ limité.

Face à la régression logistique

Le boosting capture les interactions et non-linéarités (ex. « jeune client × forte épargne ») qu'un modèle linéaire ignore — sans ingénierie manuelle lourde.

Face aux réseaux de neurones


Sur données tabulaires, le boosting est plus précis à volume modéré, plus rapide, et surtout explicable — décisif pour la confiance et l'audit.

07 · LE NEXT BEST ACTION EN DÉTAIL

De plusieurs scores à une seule offre

Chaque client possède un score par produit. Le NBA retient la meilleure offre **éligible** — et sait arbitrer quand plusieurs offres sont proches ou quand le client est déjà très sollicité.

ÉLIGIBILITÉ, PUIS ARGMAX



EXEMPLE CHIFFRÉ — CLIENT #A-2481

Produit	Score	Éligible ?	Valeur métier	Décision
Crédit conso	82	✓ oui	● ● ●	★ NBA
Carte premium	67	✓ oui	● ● ●	
Épargne	41	✓ oui	● ● ●	
Assurance auto	55	✗ non	—	exclue

Arbitrage — scores proches

Si l'écart entre deux scores est faible, on départage par la

valeur métier

(marge, priorité commerciale). Option : valeur attendue = score × valeur.

Pression & fatigue

Si le client a atteint son

plafond de sollicitations

, le NBA est différé ou remplacé — la relation prime sur le volume.

08 · L'IDENTIFICATION DU CANAL ET DU MOMENT

Le bon canal, à la bonne heure

Deux temps se succèdent : au démarrage, une segmentation comportementale (K-Means) attribue un canal et un créneau par défaut ; ensuite, l'apprentissage individuel affine selon les réactions réelles de chaque client.

1 · AU DÉMARRAGE — K-MEANS (COLD-START)



● **Cluster « Matin »** — ouvre tôt, canal Email

● **Cluster « Midi »** — réactif SMS, pause déjeuner

● **Cluster « Soir »** — Push le soir, forte conversion

Au démarrage, sans historique individuel, K-Means regroupe les clients par comportement pour attribuer un **créneau et un canal par défaut**. L'apprentissage individuel prend ensuite le relais.

2 · ENSUITE — APPRENTISSAGE INDIVIDUEL & BASCULE



Client #A-2481 : profil « soir », ouvre les Push et ignore les SMS du matin → canal recommandé **Push, créneau 20h-21h**, avec bascule SMS si non lu après 2h.

09 · EXPLICABILITÉ — SHAP

Chaque score est justifiable, variable par variable

SHAP décompose une prédiction en contributions individuelles : on voit exactement ce qui a poussé le score vers le haut ou vers le bas pour un client donné. Indispensable pour la confiance métier et la conformité.

Client #A-2481 — appétence « Crédit conso » : **score 82**


Valeur de base

50

+ contributions →

Score final

82



pousse le score vers le haut · tire le score vers le bas



Transparence

On explique pourquoi un client est ciblé — plus de « boîte noire ».



Conformité

Une décision justifiable, traçable et auditable pour le régulateur.



Actionnable

On identifie les leviers, utiles pour affiner l'offre et le discours.

10 • UNE FOIS LA CAMPAGNE LANCÉE

L'IA travaille en continu, vous gardez la main

Pendant l'exécution, l'IA optimise sans interruption. L'humain n'a pas à surveiller chaque envoi : il cadre en amont, valide les actions sensibles, et peut reprendre la main à tout moment pour ajuster les résultats attendus.

L'IA FAIT EN CONTINU

- Recalcule le score d'appétence à chaque nouvelle donnée
- Sélectionne le NBA par client (argmax sur produits éligibles)
- Choisit le canal et l'heure d'envoi les plus propices
- Déclenche les bascules de canal (smart fail-over)
- Suit les jalons et lance les actions correctives paramétrées
- Respecte les plafonds de pression et les exclusions

VOUS GARDEZ LA MAIN — POINTS DE CONTRÔLE

- 1 Cadrage — avant lancement**
objectifs, cible, offres, budget, plafonds de pression, seuils de score & d'éligibilité, jalons et actions correctives
- 2 Validation des actions à fort enjeu**
offre premium, RDV conseiller, dérogation tarifaire
- 3 En cours de campagne**
ajuster l'objectif attendu, relever/abaisser un seuil, exclure ou ajouter un segment, forcer ou bloquer un NBA ou un canal, mettre en pause
- 4 Garde-fous conformité**
la règle prime toujours ; chaque décision est journalisée

LE CYCLE

11 • GOUVERNANCE & RÔLES

Qui fait quoi, à quel moment

Une répartition claire des responsabilités sur tout le cycle : le métier décide, la data et l'IA exécutent, la conformité encadre, le conseiller agit sur le terrain.

Rôle	Cadrage	Paramétrage	Run (exécution)	Revue
Métier / Marketing	A	R	C	A
Data / IA	C	R	R	R
Conformité	C	A	I	C
Conseiller terrain	I	I	R	I

R responsable · A décideur (validation) · C consulté · I informé



Revue métier — hebdomadaire
Suivi des objectifs, ajustement des seuils et des offres, arbitrages de priorité.



Revue data — mensuelle
Contrôle des métriques (AUC, lift), réentraînement, surveillance de dérive.



Contrôle conformité — continu
Consentements, exclusions et audit trail vérifiés en permanence.

12 · APPRENTISSAGE CONTINU & MLOPS

Un modèle qui reste juste dans le temps

Les résultats de chaque campagne sont historisés et servent de vérité terrain. Les modèles sont réentraînés périodiquement sur données fraîches, et leur qualité est suivie par des métriques objectives.



MÉTRIQUES DE SUIVI

Métrique	Ce qu'elle mesure	Cible indicative
AUC-ROC	Pouvoir de discrimination (souscripteurs vs non)	$\geq 0,75$
Lift (1^{er} décile)	Gain de ciblage vs un envoi aléatoire	≥ 2 à $3\times$
Precision@k	Pertinence du top-k réellement contacté	suivi par campagne
KS	Séparation des scores bons / mauvais	$\geq 0,30$
Calibration	Écart entre conversion prédite et réelle	écart maîtrisé

BONNES PRATIQUES

- › **Réentraînement périodique**
sur fenêtre glissante de données récentes
- › **Surveillance de dérive**
alerte si les performances se dégradent
- › **Versionnage**
modèles et jeux de données tracés
- › **Validation avant mise en prod**
un modèle ne remplace le précédent que s'il fait mieux

13 · FIL ROUGE — UN CLIENT DE BOUT EN BOUT

Le parcours du client #A-2481, étape par étape

Pour rassembler l'ensemble : de la donnée d'entrée jusqu'à l'apprentissage, voici comment un même client traverse le moteur prédictif et l'orchestration.



EN RÉSUMÉ

Un score expliqué, une décision justifiée, un modèle qui apprend.

Règles d'abord, ML ensuite — l'humain cadre et arbitre, l'IA exécute et s'améliore. Une solution Stratawise Africa.